

SQL znalosti

Bez AI Prosím o nevyužívání AI ani vyhledávání funkcí

Zadání

Jeden z úkolů datového analytika je třeba umět kontrolovat SQL, které vedou k výstupu dat. Prosím o přečtení a pochopení SQL dotazu a zodpovězení otázek pod ním. Cíl Jedná se o ukázkový SQL dotaz střední náročnosti, který běžně generujeme v rámci naší práce a je důležitá schopnost tento dotaz umět rychle přepsat a pochopit.

SQL Dotaz

```
SELECT
-- Network (rozdělujeme výdej reklamy ve vyhledávání nebo bannerovou reklamu v obsahové síti).
o.NETWORK,
c.NAME AS CAMPAIGN_NAME,
COUNT(DISTINCT o.USER_ID),
-- Reklamy jsou v účtu dělené do struktury Kampaň -> Sestava (Groups) -> Samotná reklama).
COUNT(DISTINCT o.GROUP_ID),
SUM(o.IMPRESSIONS),
SUM(o.CLICKS),
SUM(o.MONEY),
ROUND(SUM(o.CLICKS) * 100.0 / NULLIF(SUM(o.IMPRESSIONS), 0), 2),
CASE
WHEN SUM(o.MONEY) >= 50000 THEN 'CAT 1'
WHEN SUM(o.MONEY) >= 5000 THEN 'CAT 2'
ELSE 'CAT 3'
END
FROM ADVERTISING.SKLIK.COMPLETE_OVERVIEW o
LEFT JOIN ADVERTISING.SKLIK_CAMPAIGN c
ON o.CAMPAIGN_ID = c.ID
WHERE o.DT >= DATEADD(day, -7, CURRENT_DATE)
AND o.DSP = 'sklik'
GROUP BY o.NETWORK, c.NAME
HAVING SUM(o.IMPRESSIONS) > 1000
ORDER BY SUM(o.IMPRESSIONS) DESC
LIMIT 20;
```

Otázky k zodpovězení

1. Co představuje jeden řádek výsledku a k jakému období se vztahuje? **jeden řádek = jedna kombinace typu sítě (NETWORK) a názvu kampaně (CAMPAIGN_NAME), od data CURRENT_DATE - 7 dní včetně dnešního dne, pouze pro DSP = 'sklik', výsledek je omezen na 20 skupin s více než 1000 impresemi, seřazené od největšího počtu impresí.**

2. Proč je použit ``LEFT JOIN``, a ne ``INNER JOIN``? `INNER JOIN` zobrazí jen všechny na sebe navázané záznamy, `LEFT JOIN` nám zajistí, že ke všem záznamům v `o` (`ADVERTISING.SKLIK.COMPLETE_OVERVIEW`) se doplní příslušná data z `c` (`ADVERTISING.SKLIK_CAMPAGN`), pokud by z druhé tabulky neexistoval příslušný záznam k první tabulce, tak se napíše `NULL`.

3. Jaký je rozdíl mezi ``COUNT(DISTINCT o.USER_ID)``, ``COUNT(o.USER_ID)`` a ``COUNT(*)`` — a proč by v tomhle dotazu dávalo použití špatné varianty zavádějící číslo? Použití `DISTINCT` nám spočítá jen unikátní hodnoty, `COUNT(o.USER_ID)` uvede počet všech nenulových hodnot `USER_ID` a `COUNT(*)` uvede počet všech řádků (i těch, kde by `USER_ID` nebyl uveden). Zavádějící by použití špatné varianty bylo proto, že by číslo mohlo vypadat jako počet uživatelů, ale ve skutečnosti by měřilo počet záznamů. V tomto dotazu se počítá počet uživatelů v rámci každé skupiny `NETWORK + CAMPAIGN_NAME`

4. K čemu slouží ``NULLIF(SUM(o.IMPRESSIONS), 0)`` ve výpočtu? Jaké chybě to předchází a co by se bez toho mohlo stát? Tato část příkazu je součástí dělení, pokud by `IMPRESSIONS` byly 0, tak by výsledek byla chyba, protože dělit nulou nelze, tudíž tato část příkazu nám pomáhá předejít chybové hodnotě a v těchto případech se do řádku napíše `NULL`. Kdybychom chtěli nad tímto sloupcem dat pokračovat s dalšími výpočty, tak bez tohoto opatření by mohla vyskočit rovnou chyba.

5. Proč je filtr na datum (``o.DT >= ...``) ve ``WHERE``, ale filtr na objem (``SUM(o.IMPRESSIONS) > 1000``) až v ``HAVING``? Šlo by je prohodit? Pokud chceme použít podmínku (filtr) na agregovaný výsledek (`SUM`, `COUNT`, ..) tak použijeme `HAVING`, `WHERE` použije jako jednoduchá podmínka přímo pro nějaký sloupec hodnot, jako zde pro datum. `WHERE` filtruje řádky ještě před seskupením a výpočtem agregací, `HAVING` se vyhodnocuje až po `GROUP BY` a agregaci, a proto je nemůžeme prohodit.

6. Co by se změnilo ve výsledku, kdyby ``GROUP BY`` obsahoval jen ``o.NETWORK`` (bez ``c.NAME``)? Kdyby `GROUP BY` obsahoval pouze `o.NETWORK`, agregace by se počítaly jen pro jednotlivé hodnoty `NETWORK`, takže by se kampaně v rámci stejného networku sloučily do jedné skupiny. Zároveň by ale v `SELECT` zůstalo `c.NAME`, které není ani agregované, ani uvedené v `GROUP BY`, takže by dotaz skončil chybou.

7. Jak funguje ``CASE WHEN``? Proč záleží na pořadí podmínek (``>= 50000`` před ``>= 5000``) a co by se stalo, kdyby se prohodily? K čemu slouží větev ``ELSE`` a co by se stalo bez ní pro řádek, který nesplní žádnou ``WHEN`` podmínku? `CASE WHEN` nám pomáhá výsledky rozdělit do námi určených kategorií. Prohodit by to nešlo, protože jinak by nám vznikly jen dvě kategorie, `CAT 2` a `CAT 3`, výsledky rovné a nad 50 000 by se rovnou zařadily do `CAT 2`. `ELSE` nám říká, kam zařadit všechny záznamy, pro které neplatí žádná z podmínek. Bez `ELSE` by se k záznamům nespádajících do podmínek napsalo `NULL`.

Obecné analytické, deduktivní uvažování

Dvě rychlé otázky na zamyšlení. Prosím bez využití AI.

1/ Je možné z dat jednoznačně určit, který web měl na základě dat nejvíce prokliků? Odůvodněte.


Web	Imprese	Konverze
zive.cz	310	58
aazdravi.cz	100	5
pocasi.cz	298	100
seznam.cz	658	343
csfd.cz	187	200

Neznám definici konverze, mohu se například pouze domnívat, že “počet prokliků u daného webu bude vždy číslo menší než imprese a vždy větší než konverze” (imprese $\geq$ proklik $\geq$ konverze). Pokud by počet konverzí u některého webu převyšoval celkový počet impresí všech ostatních webů, pak by za předpokladu, že každá konverze vzniká až po prokliku, bylo možné usuzovat, že tento web měl nejvíce prokliků. V tomto případě by to byl seznam.cz. Protože ale neznám přesnou definici konverze ani vztah mezi konverzemi a prokliky, nelze tento závěr považovat za jistý.

Můžeme ale sledovat i více konverzí najednou, tak by jeden klik u jednoho uživatele mohl vyústit v 2 konverze (např. registrace a nákup), příkladem této úvahy může být web [csfd.cz](#) (pokud se zde nejedná o chybu), kde je počet konverzí vyšší než počet impresí. Tato úvaha tak vyvrací tu první.

Máme k dispozici pouze počet impresí a konverzí, ale neznáme počet kliků ani přesnou definici konverze a její vztah ke klikům. Nelze tedy předpokládat, že web s nejvyšším počtem impresí nebo konverzí měl zároveň nejvíce prokliků.

2/ Příklad vývoje impresí a kliků jednoho inzerentského účtu (campaign.png). Na základě grafů zkuste odhadnout obor daného inzerenta a popsat jednotlivá období v grafu.



V grafu je vidět výrazný růst na jaře, vrchol přibližně v dubnu, potom poměrně rychlý pokles během května a června. Přes léto až podzim jsou imprese i kliky nízké a relativně stabilní. Od listopadu znovu roste a v prosinci je vidět druhý nejlepší výkon. Kliky většinou kopírují vývoj impresí. Podle tohoto vývoje usuzuji, že se jedná o sezónní obor, typu sezónní zboží (Velikonoce, Vánoce, Halloween, ...), cestování, zahradní vybavení apod.